ANTHROPIC ENGINEERING | 2026 年 4 月 23 日

Claude Code 质量复盘

三个产品层变更，如何叠加成“模型整体退化”的用户感受。

先看结论

3	0	4 月 20 日
个独立变更	API 或推理层影响	问题全部修复

> *不同流量切片、不同发布时间，最终汇成一个难以判断的质量信号。*

变更时间线

3 月 4 日

默认推理强度下调：从 high 改为 medium，以降低延迟。

3 月 26 日

上线思考清理：面向长时间空闲会话，但错误地每轮都触发。

4 月 16 日

加入简洁性提示词：之后被发现会降低编码质量。

4 月 20 日

最后一个回归被回滚；v2.1.116 中完成修复。

问题一：推理强度默认值

初衷

降低少数用户遇到的超长思考延迟，避免界面看起来像卡死。

影响

Medium 降低了延迟，但让用户在编码任务中感到能力下降。

4 月 7 日已回滚：Opus 4.7 默认 xhigh，其他模型默认 high。

问题二：历史思考被丢弃

空闲会话
超过一小时后，本应只清理一次旧思考。

→

错误标记
清理逻辑变成每一轮都继续触发。

→

理由丢失
Claude 变得像是健忘、重复、工具选择异常。

问题三：过度限制输出长度

“工具调用之间的文本不超过 25 个词；除非任务需要更多细节，最终回复不超过 100 个词。”

为什么会上线

Opus 4.7 更容易冗长，而内部测试没有显示明显回归。

后来发现什么

更广泛的消融测试发现约 3% 下降，因此 4 月 20 日回滚。

为什么难以定位

变更相互叠加

每个变更影响的人群和时间窗口都不同。

评测没有覆盖

初始内部使用和测试未能复现用户报告。

触发条件偏窄

思考丢失问题依赖空闲会话和特定轮次模式。

Anthropic 将如何改进

更多内部员工使用公开版本，而不是只使用实验构建。

增强代码审查，让评审工具能拿到更完整的仓库上下文。

收紧提示词变更控制：按模型评测、消融分析、审计工具。

更安全地发布智能权衡变更：观察期、更宽评测、渐进 rollout。

核心教训

质量是系统属性

模型行为、产品默认值、上下文管理、提示词、评测和发布流程，都会共同塑造用户体验。